Data Science - 2024

REST for Big-Data

ElasticSearch for Big-Data

Master Data Science

Last update: Déc. 2024

Introduction à ElasticSearch

- Définition : Elasticsearch est un moteur de recherche et d'analyse distribué basé sur Apache Lucene.
- **Utilisation principale :**
  - Recherche rapide dans de grands volumes de données.
  - Analyse en temps réel.
- **Caractéristiques clés :**
  - Basé sur un modèle NoSQL.
  - Supporte la recherche full-text et les agrégations.
  - Extensible et scalable.
- **Cas d'utilisation :**
  - Journaux système (log management).
  - Monitoring (observabilité avec Elastic Stack).
  - Recherche textuelle sur des sites web (e.g., moteur de recherche e-commerce).

Pourquoi Elasticsearch ?

- **Avantages par rapport à d'autres solutions :**
  - Performances : Recherche en millisecondes grâce aux index.
  - Scalabilité : Fonctionnement distribué par nature.
  - Flexibilité : Supporte des documents JSON semi-structurés.

- **Comparaison avec des bases de données traditionnelles :**
  - Optimisé pour la recherche rapide et les agrégations.
  - Indexation des données pour accélérer les requêtes.

- **Importance dans le Big Data :**
  - Gestion et analyse de données massives.
  - Intégration avec Hadoop, Logstash, Kibana, etc.

Concepts fondamentaux – Cluster et Noeuds

- **Cluster : Un ensemble de nœuds Elasticsearch travaillant ensemble.**
  - Nom unique : Chaque cluster a un identifiant unique.
  - Scalabilité horizontale : Ajout ou suppression de nœuds facilement.
- **Nœuds : Instances Elasticsearch dans un cluster.**
  - Types :
    - Master Node : Coordonne le cluster.
    - Data Node : Stocke et traite les données.
    - Ingest Node : Traite les documents avant l'indexation.
  - Communication via API RESTful.

Concepts fondamentaux - Index

- Index: Équivalent à une "base de données" dans Elasticsearch.
- **Structure :**
  - Shards : Sous-divisions d'un index, permettant la distribution.
  - Replicas : Copies redondantes pour la tolérance aux pannes.
- **Création d'un index :**
  - PUT /mon_index
  - {
  - "settings": {
  - "number_of_shards": 3,
  - "number_of_replicas": 1
  - }
  - }
- **Requêtes associées :**
  - Création, mise à jour, suppression.
  - Recherche et agrégations.

Document et mappage

- Document : Unité de données dans Elasticsearch (JSON).
  - Exemple :
    - {"titre": "Elasticsearch","auteur": "Elastic","date": "2024-01-01","tags": ["recherche", "analyse"]}
- Mapping : Décrit la structure et le type des données d'un index.
  - Exemple :
    - PUT /mon_index
    - {
    - "mappings": {
    - "properties": {
    - "titre": { "type": "text" },
    - "date": { "type": "date" }
    - }
    - }
    - }
- **Elasticsearch gère dynamiquement les types si aucun mappage n'est défini.**

Recherche dans Elasticsearch

- Requêtes basiques :
  - Recherche par correspondance :
  - GET /mon_index/_search
  - {
  - "query": {
  - "match": {
  - "titre": "Elasticsearch"
  - }
  - }
  - }

Recherche dans Elasticsearch

- Requêtes booléennes :
  - Combinaison de conditions (must, should, must_not).
- Requêtes full-text :
  - Prise en charge de la recherche floue, correspondance partielle.
  - Exemple :
    - GET /mon_index/_search
    - {
    - "query": {
    - "match": {
    - "tags": "analyse"
    - }
    - }
    - }

Agrégations

- Définition : Permet de résumer, analyser et agréger des données.
- **Types d'agrégations :**
  - Statistiques : Moyenne, minimum, maximum.
  - Bucket : Groupement de données (e.g., par date, catégorie).
- **Exemple : Compter les documents par "tags".**
- GET /mon_index/_search
  - {
  - "aggs": {
  - "par_tags": {
  - "terms": {
  - "field": "tags.keyword"
  - }
  - }
  - }
  - }

Indexation

- Indexation :
    - Ajout de documents dans un index.
- POST /mon_index/_doc
- {
- "titre": "Exemple d'indexation",
- "contenu": "Introduction à Elasticsearch"
- }

Pipeline d'ingestion

- **Transformation des données avant indexation.**

- **Exemple : Ajout d'un champ calculé.**

```
PUT _ingest/pipeline/mon_pipeline
{
  "processors": [
    {
      "set": {
        "field": "nouveau_champ",
        "value": "valeur par défaut"
      }
    }
  ]
}
```

Monitoring et Sécurité

- **Monitoring :**
  - Outils natifs : Kibana (Tableaux de bord).
  - Analyse des performances via /_cat API.
    - GET /_cat/indices?v
- **Sécurité :**
  - Authentification avec Elastic Security.
  - Communication chiffrée via SSL/TLS.
  - Gestion des rôles et utilisateurs.
    - POST /_security/user/admin

```
{
  "password": "password",
  "roles": ["superuser"]
}
```

Intégrations et Cas d'utilisation

- **Intégrations :**
  - Logstash : Import et transformation de données.
  - Kibana : Visualisation et tableaux de bord.
  - Beats : Collecte de journaux.

- **Cas pratiques :**
  - E-commerce : Recherche de produits.
  - Analytics : Suivi des utilisateurs en temps réel.
  - Observabilité : Gestion des logs (stack ELK).

Documentation et lecture

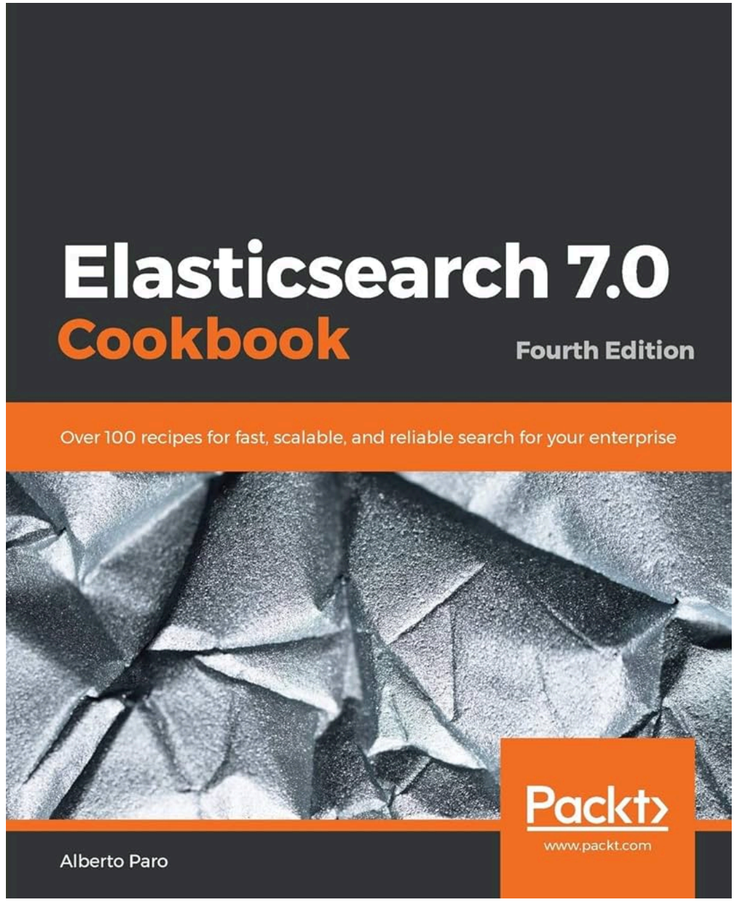

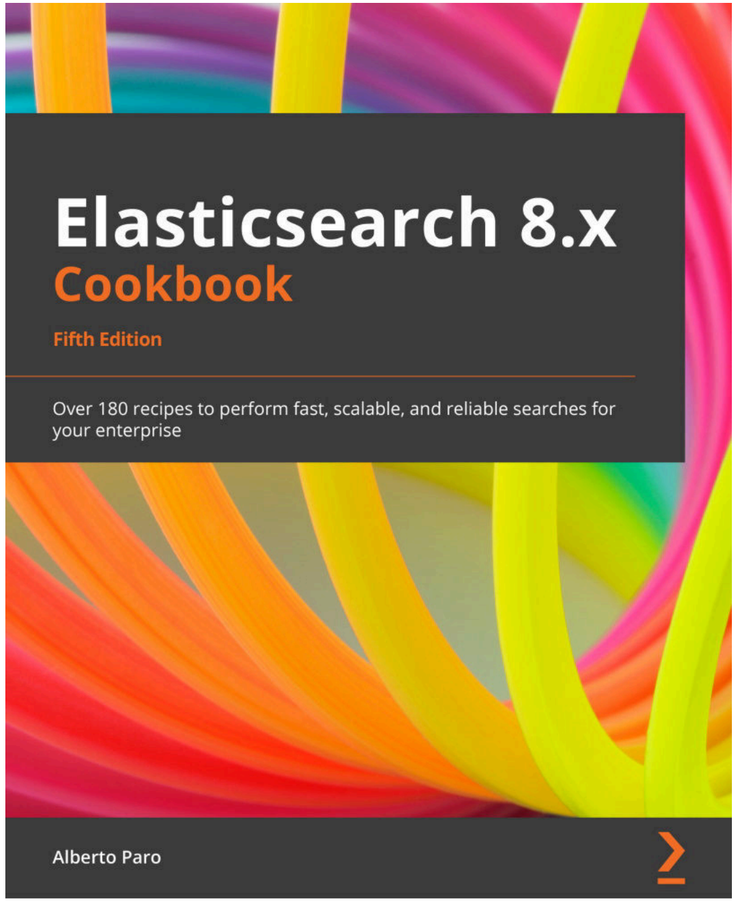

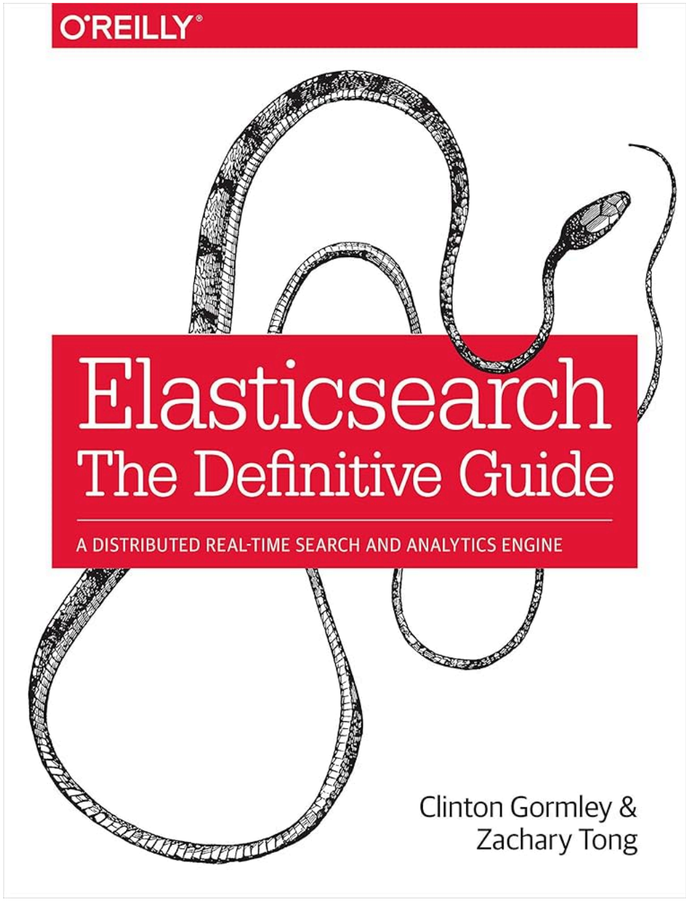

+ la documentation sur site Officiel : www.elastic.co